

# Segmentación y clasificación de melanomas basada en forma, textura y color.

Pedro Sánchez

*Máster Universitario en Bioinformática para las Ciencias de la Salud*

*Universidade da Coruña*

A Coruña, España

p.sanchezg@udc.es

**Abstract** – Entre los diferentes tipos de cáncer, el melanoma es de los más mortíferos. En consecuencia, es necesario su diagnóstico temprano por sistemas computacionales que permitan la evaluación y clasificación de cada lesión cutánea analizada en el paciente. Para lograrlo, la segmentación adecuada de la imagen es un factor de gran relevancia. En el presente trabajo se presenta una metodología basada en umbralización y operadores morfológicos para segmentar la región de interés que abarca la lesión. Posteriormente, mediante extracción de características relacionadas con texturas, formas y colores, se establece un clasificador k-nearest neighbors para distinguir, con buenos resultados como en el caso de texturas, aquellas lesiones cutáneas que se tratan de melanoma.

**Palabras clave** – Detección de melanoma, segmentación, imágenes dermatoscópicas, clasificación.

## I. INTRODUCCIÓN

El melanoma es un cáncer que comienza en células de la piel denominadas melanocitos, que se encargan de producir el pigmento de la melanina. Su reconocimiento y tratamiento temprano resultan cruciales, pues su extensión a diferentes órganos puede desencadenar otros problemas. Para ello, habitualmente se emplea la regla ABCD para distinguir entre lesiones benignas y casos de melanoma, donde A es la asimetría de la lesión, B conforma el borde, es decir, irregularidades y salientes, C hace referencia al color y D, por su parte, es el diámetro.

Es importante tener en cuenta que, en el melanoma, se produce asimetría, mayor diámetro, falta de uniformidad en color y mayor rugosidad en lo que respecta a la textura. De esta forma, existen diferentes metodologías que se basan en todas estas características e incluso en múltiples combinaciones, lo que permite llevar a cabo una clasificación con resultados adecuados. No obstante, esto precisa una primera fase para la extracción de la lesión cutánea con la mejor precisión posible. Para ello, se debe eliminar vello, reglas y otros artefactos en la imagen que puedan alterar este proceso.

En consecuencia, este artículo comprende una metodología para la segmentación y, por tanto, generación de la máscara de la lesión, así como para la clasificación de los resultados de segmentación en lesiones benignas o melanoma.

## II. METODOLOGÍA PROPUESTA

### A. Extracción de lesiones dermatológicas

En primer lugar, se lleva a cabo un preprocesamiento de las imágenes con el fin de eliminar el vello y otros elementos que puedan interferir. Esta etapa se basa en el programa DullRazor y comprende las siguientes fases:

- 1) Aplicación de bottom-hat con un kernel de tamaño 17 sobre la imagen.
- 2) Umbralización global de la imagen alcanzada en fase anterior.
- 3) Interpolación de las estructuras de vello y sustitución por valores de píxeles más próximos en imagen original.
- 4) Suavizado de imagen alcanzada mediante un filtro de medianas con tamaño 5.

Posteriormente, se lleva a cabo la segmentación, de forma que se aísla la lesión cutánea del resto de piel normal. Se trata de un proceso que mantiene la rigurosidad y aproximación a la morfología de la lesión, conformando las siguientes fases:

- 1) Umbralización Otsu y `thres_tozero`, con posterior apertura para eliminación de ruido.
- 2) Uso de una función del paquete `scikit-image` para seleccionar el área más grande sobre la imagen alcanzada en la fase 1.
- 3) Aplicación de cierre morfológico, dilataciones y erosiones con kernel de tamaño 17 y valores de 8 y 5 iteraciones para estas dos últimas.

En términos generales, se trata de alcanzar una segmentación en la que no haya huecos en la región de interés extraída y, además, se ajuste la morfología en la medida de lo posible a las respectivas máscaras proporcionadas.

Para tener conocimiento del alcance en la metodología planteada, se procede a la validación estadística por medio de la métrica de intersección sobre unión (IoU), que proporciona el porcentaje de solapamiento de las regiones que hemos segmentado y de las máscaras correspondientes al *ground truth*:

$$IoU = \frac{|S \cap GT|}{|S \cup GT|}$$

#### B. Clasificación de lesiones dermatológicas

Para este procedimiento, se centra la atención en diferentes características distintivas de lesiones cutáneas, que se extraen para cada imagen:

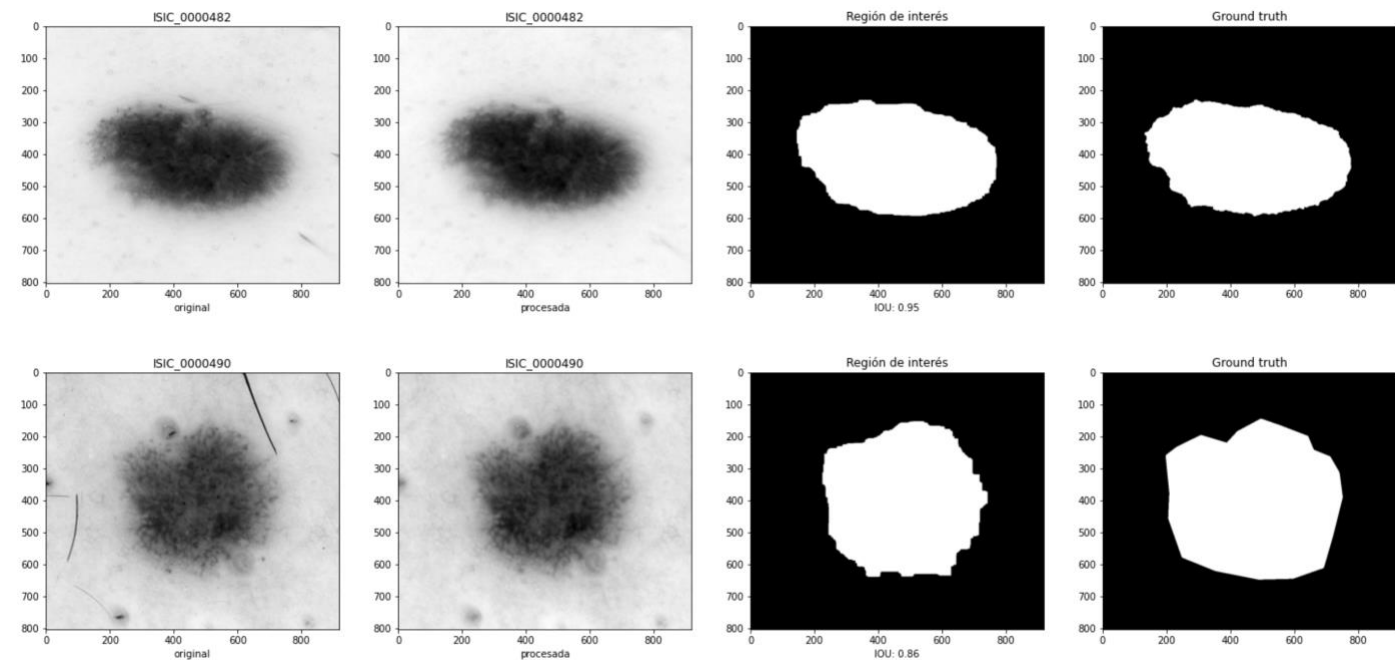
- Texturas (media, varianza y entropía).
- Texturas (matriz de co-ocurrencia: contraste, energía, correlación y homogeneidad).
- Descriptores de formas (área, perímetro, diámetro e índice de irregularidad).
- Colores (media de valores en espacio RGB).

Además, se llevan a cabo combinaciones de las aproximaciones por colores con descriptores de formas y texturas respectivamente. A continuación, con las características extraídas, se emplea el clasificador k-nearest neighbors (KNN) bajo un valor de  $k=3$  en la *k-fold* como técnica de validación cruzada. Por último, se determina el porcentaje de aciertos en el conjunto de test, que pone de manifiesto la robustez del clasificador y metodología utilizadas.

III. RESULTADOS.

A. Extracción de lesiones dermatológicas

A continuación, se muestran imágenes representativas de los resultados para diferentes fases realizadas en este procedimiento:



En la primera columna, se muestra la imagen original con vello. Posteriormente, se representa la imagen procesada sin vello ni artefactos tras aplicar las técnicas explicadas anteriormente. Las dos últimas columnas corresponden con la región de lesión cutánea extraída manualmente y el *ground truth* respectivamente.

Con respecto a la IoU calculada, se logra el siguiente resultado global:

IoU (media ± desviación estándar)
0.85 ± 0.11

Tal y como se puede observar, en términos generales los resultados de IoU son superiores a 0.80 en un amplio número de imágenes analizadas. Esto pone de manifiesto que la metodología implementada permite alcanzar una segmentación con una correspondencia adecuada con el *ground truth*. Con respecto a las imágenes donde se reducen notablemente los valores, cabe destacar que esto no se podría atribuir por la presencia de vello o de reglas, sino a condiciones como luminosidad, filtros empleados para el suavizado y operadores morfológicos posteriores. Con respecto a estas condiciones mencionadas, para futuros trabajos sería importante evaluar rigurosamente aquellos parámetros adecuados que permitiesen mejorar los resultados para la IoU empleada.

### B. Clasificación de lesiones dermatológicas

A continuación, para cada aproximación planteada, se reflejan los resultados correspondientes al porcentaje de acierto en test con el clasificador KNN:

Características	% acierto
Texturas	88.23
Texturas (matriz de co-ocurrencia)	41.18
Descriptores de formas	41.18
Colores	58.82
Colores y descriptores de formas	64.70
Colores y texturas	64.70

En general, se aprecia que el mejor resultado se logra con la aproximación de texturas, seguido de la combinación de colores con descriptores de formas y texturas respectivamente. De este modo, resulta evidente que la aproximación planteada con colores, matriz de co-ocurrencia y descriptores de formas no contribuyen a un resultado adecuado en la clasificación de las lesiones cutáneas.

### IV. CONCLUSIONES

La metodología de segmentación planteada en este trabajo para imágenes dermatoscópicas permite aislar la región de interés correspondiente a la lesión cutánea analizada. El resultado de IoU medio para el conjunto de imágenes proporcionado indica un buen comportamiento de las fases propuestas en la metodología.

En lo referente a la clasificación, se han extraído diversas características de la región correspondiente a la lesión cutánea. Los resultados obtenidos indican que el empleo de medidas relacionadas con textura proporciona un mayor porcentaje de acierto y por tanto, robustez en el sistema de clasificación de lesiones cutáneas por el clasificador KNN. Además, cabe destacar que la combinación de aproximación con colores y descriptores de formas incrementa el porcentaje de aciertos en comparación con el uso de ambas características por separado.

Para futuros trabajos, sería interesante incrementar el tamaño del conjunto, realizando pruebas de la metodología presentada en un amplio número de imágenes. Por otro lado, se explorarían otras características que permitiesen incrementar el porcentaje de aciertos analizado.